

# 一 你是怎样获取bert-base-chinese模型的？

---

先科学上网，然后通过访问 Hugging Face 模型库获取了 bert-base-chinese 模型。

## 二 你获取数据集的方式，为什么选择该数据集？

---

- 网上直接搜索中文商品评价数据集。
- 初始数据集上万条，数据足够丰富。

## 三 你是否对数据集进行了预处理优化？如果是，请写出你的优化手段以及用你的理解告诉我们为什么要进行预处理。

---

### 数据清洗

- 1 去重 重复样本会放大某些句式的权重，导致过拟合。
- 2 去异常 极短句/乱码几乎无情感信息；极长会被截断，表达信息不完整。
- 3 去除部分标点 混乱标点让分词产生大量稀有 token；适度保留情感标点能保留强烈/疑问语气信息。

### 数据增强

- 1 同义词替换 用意义相近的词替换原词，扩大词汇表达，减少模型对固定词语的依赖。
- 2 随机插入 在句中加入语气词或副词，模拟口语冗余，使模型更能适应真实表达。
- 3 随机删除 随机删掉部分非关键字，让模型学会在信息不完整时仍能判断情感。

## 四 emoji表情是当作脏数据还是情感标签？

---

### 先简述：既当作脏数据又作为情感标签

- 情感标签：由于数据集自身没有好中差的标签，所以我需要先给数据集设标签以供模型学习，对于设标签来讲我认为emoji表情（如 开心和生气）几乎可以直接判断该数据是属于哪个标签，所以在设标签时我借助emoji来设置标签。
- 脏数据：由于我在打标签阶段用 emoji 作为判断情感的依据，如果训练数据还保留这些表情，可能会造成模型会直接“背答案”，学到“出现 😄 就是好评”，造成模型对于文本内容不重视，从而使模型泛化差。

## 五 你采取的优化方式，并详细讲解为什么这种方式可以优化模型以及其优化逻辑

---

我先用四个学习率训练模型（全部解冻），根据 eval\_acc（预测准确率）和 eval\_macro\_f1（衡量模型平衡性、防止类别偏置）确定最佳学习率。再用该学习率分别训练两个批次，选出最优批次后继续在此基础上尝试不同轮数。在此期间设置的早停通过持续监控验证集指标（eval\_acc和 eval\_macro\_f1），当几轮都没提升时自动停止训练，最终确定最优参数组合为：学习率 2e-5，批次 32，轮数 6。

学习率：太大容易一步跨过最优点，太小又导致浪费时间还容易陷入局部最优。

批次：大batch稳但易过拟合，小batch噪声大但泛化好，在已固定 LR 下找到折中点。

轮数：轮数不合适容易欠拟合或者过拟合，在已固定 LR 和BA下找到折中点。

早停：模型训练时，验证集性能上升到最高时会下降，继续训练只会让模型死记训练数据。所以它既可以节省时间和算力又可以让最终模型停在“泛化最好”的点。

## 六 你对优化后的模型在验证集上的准确率有什么样的结论？

---

可以在 七 看到指标优化很大 主要看前三项 验证集损失降低 验证集准确率提高 验证集平衡参考值提高

## 七 模型优化前后准确率的记录

---

第一张照片是模型的初始性能

第二张照片是模型全参数训练后的性能

第三张照片是模型在最优学习率，批次，循环数的基础上全参数训练后的性能

```
{  
  "eval_loss": 1.4920194149017334,  
  "eval_acc": 0.11984021304926765,  
  "eval_macro_f1": 0.11887349023329534,  
  "eval_model_preparation_time": 0.0014,  
  "eval_runtime": 3.9152,  
  "eval_samples_per_second": 191.816,  
  "eval_steps_per_second": 6.13  
}
```

```
{  
  "eval_loss": 0.06108446791768074,  
  "eval_acc": 0.9880159786950732,  
  "eval_macro_f1": 0.9593979638438329,  
  "eval_runtime": 3.1455,  
  "eval_samples_per_second": 238.755,  
  "eval_steps_per_second": 7.63,  
  "epoch": 3.0  
}
```

```
{  
  "eval_loss": 0.03726549074053764,  
  "eval_acc": 0.9946737683089214,  
  "eval_macro_f1": 0.9854504562732181,  
  "eval_runtime": 3.0635,  
  "eval_samples_per_second": 245.142,  
  "eval_steps_per_second": 7.834,  
  "epoch": 6.0  
}
```

## 八 你的github仓库连接

---

<https://github.com/aihuiyuan/SCC>